Documentation des métriques

Module enricher/trend_detection

Pipeline de détection de tendances et de signaux faibles sur les topics arXiv

13	3	4	6
métriques analytiques	familles de métriques	scores calculés	états de classification

Table des matières

1. **Vue d'ensemble du pipeline**
2. **Famille 1 : Tendance volumétrique**
   - 2.1 Z-score glissant
   - 2.2 Pente OLS
   - 2.3 Test de Mann-Kendall
   - 2.4 Exposant de Hurst
   - 2.5 CAGR
3. **Famille 2 : Signal faible**
   - 3.1 Emergence score
   - 3.2 Novelty-Weighted Emergence (NWE)
   - 3.3 Persistence score
   - 3.4 Burst score (Kleinberg)
4. **Famille 3 : Sémantique DST**
   - 4.1 Semantic drift
   - 4.2 Keyword drift
   - 4.3 Stability score
5. **Scores dimensionnels et score composite**
6. **Classifieur : 6 états**
7. **Tableau récapitulatif**

1. Vue d'ensemble du pipeline

Le module `trend_detection` est un pipeline batch mensuel qui analyse l'évolution des topics scientifiques détectés par BERTopic dans les publications arXiv. Il repose sur **13 métriques analytiques** organisées en trois familles complémentaires, combinées en un score composite qui pilote une classification à 6 états.

1	**Snapshot**	Agrégation mensuelle par topic (TopicSnapshot)
2	**Storage**	Persistance des snapshots et de l'historique
3	**Ingestion**	Construction des séries temporelles (TimeSeriesBuilder)
4	**DST**	Agrégation des centroïdes d'embeddings (si activé)
5	**Analyse**	Calcul des 13 métriques + classification hybride
6	**Output**	Export JSON/Parquet pour le dashboard Streamlit

FAMILLE 1

2. Tendance volumétrique

Ces cinq métriques analysent la **série temporelle du nombre d'articles par mois** pour détecter une croissance ou un déclin structurel. Elles constituent le score `trend_score` avec pondération α (défaut : 0,4).

2.1 Z-score glissant

Équation :

```
z[t] = (x[t] - mean[t-w:t]) / std[t-w:t]
```

où **w** est la taille de la fenêtre glissante (défaut : 6 mois), mean et std sont la moyenne et l'écart-type calculés sur les *w* mois précédents.

Le z-score ne mesure pas une tendance globale : il détecte si le volume du mois courant est **localement anormal** par rapport à la fenêtre récente. C'est une mesure d'*accélération soudaine*, complémentaire à Mann-Kendall qui analyse la série entière. Un z-score nul représente un score neutre de 0,5 après normalisation par sigmoïde (scale=1,5).

`|z| < 1,0`	Volume dans la plage habituelle
`z > +2,0`	Pic anormal : top 2,5 % de la fenêtre
`z < -2,0`	Creux anormal : effondrement du volume

Cas dégénéré : si l'écart-type de la fenêtre est nul (tous les mois identiques), la valeur courante différente est codée ±3,0 selon sa direction.

2.2 Pente OLS (Ordinary Least Squares)

Équation :

```
a = Sum[ (t - t_bar) * (x_t - x_bar) ] / Sum[ (t - t_bar)^2 ]
```

avec t = 0, 1, 2, ..., n-1

La pente **a** représente le nombre d'articles supplémentaires par mois en tendance linéaire. Elle est **globale** et stable, mais suppose une relation linéaire. Pour des tendances exponentielles ou en plateau, Mann-Kendall est plus adapté : c'est pourquoi les deux métriques coexistent dans le `trend_score`.

Normalisation : sigmoïde avec scale=0,5. Une pente nulle donne 0,5 (score neutre).

2.3 Test de Mann-Kendall

Équation :

```
tau = S / C(n,2) avec S = sum_{i<j} sgn(x_j - x_i)
```

Implémenté via `scipy.stats.kendalltau(t, série)`, équivalent au test Mann-Kendall classique. C'est la métrique **directionnelle centrale** du système.

- Non-paramétrique : aucune hypothèse de distribution normale
- Robuste aux outliers et aux plateaux prolongés
- Détecte les tendances non-linéaires (exponentielle, sigmoïde, escalier...)

p-value : la significativité statistique est critique. Le classifieur exige p <= 0,05 pour TRENDING et p <= 0,10 pour DECLINING. Un tau élevé sur une courte série peut être dû au hasard : la p-value filtre ces faux positifs.

Subtilité d'implémentation : Mann-Kendall est calculé sur `vol_active` (mois avec au moins 1 article). Les mois à zéro génèrent de l'anti-persistance artificielle qui fait chuter tau même si les mois actifs montrent une vraie tendance.
Normalisation : (tau + 1) / 2 : transformation linéaire depuis [-1, 1] vers [0, 1].

2.4 Exposant de Hurst

Méthode R/S (Rescaled Range, Hurst 1951) :

```
R(n) = max(X_k - X_bar) - min(X_k - X_bar)
```

```
S(n) = sigma_n
```

```
R/S(n) = R(n) / S(n)
```

```
log(R/S) ~ log(n) => H = pente
```

Hurst répond à la question fondamentale : *la tendance détectée par Mann-Kendall est-elle réelle ou du bruit ?*

`H > 0,5`	Série PERSISTANTE : les hausses tendent à continuer
`H = 0,5`	Marche aléatoire : le futur est indépendant du passé
`H < 0,5`	Série ANTI-PERSISTANTE : alternances hausse/baisse

Complémentarité avec Mann-Kendall : un topic avec tau >= 0,40 ET H >= 0,55 est un signal TRENDING très fiable. Sans Hurst, on risque de classer comme TRENDING un topic dont la croissance est du bruit à mémoire courte.

2.5 CAGR (Compound Annual Growth Rate)

Équation :

```
CAGR = (V_final / V_initial) ^ (12 / n_mois) - 1
```

Le CAGR normalise la croissance sur une **base annuelle**, permettant de comparer des topics avec des historiques de durées différentes.

Exemple : 10 -> 40 articles en 24 mois -> CAGR ≈ +41%/an. Le même ratio en 12 mois -> CAGR = +300%/an.

Limite : le CAGR ne capture pas la volatilité intermédiaire. V_initial et V_final sont les premiers et derniers points *non nuls* pour éviter les divisions par zéro sur les topics inactifs en début ou fin de période.

FAMILLE 2

3. Signal faible

Ces quatre métriques cherchent les **topics en émergence** : faible volume absolu, forte dynamique de croissance, et/ou comportement anormal détecté par un automate probabiliste. Elles constituent le score `weak_signal_score` avec pondération β (défaut : 0,4).

3.1 Emergence score

Équation :

```
emergence[t] = growth_rate[t] / log(1 + x[t])
```

```
growth_rate[t] = (x[t] - x[t-1]) / x[t-1]
```

Le diviseur **log(1 + x)** est la clé de la métrique. Il pénalise les topics à grand volume : pour x = 500, log(501) ≈ 6,2, rendant modéré même un fort taux de croissance. Un topic avec 5 articles qui double obtient un score bien supérieur à un topic avec 500 articles qui progresse de 10%.

Cas spécial : si le mois précédent avait 0 articles (naissance du topic), growth_rate = 1,0 si le mois courant est non nul, sinon 0.

3.2 Novelty-Weighted Emergence (NWE)

Équation :

```
NWE[t] = max(0, novelty[t]) * growth_rate[t]
```

Le NWE combine deux dimensions complémentaires qui, prises séparément, génèrent des faux positifs :

`novelty_score`	Isolement sémantique moyen des articles (calculé par SPECTER). 1,0 = articles uniques, non absorbés par les topics établis.
`growth_rate`	Taux de croissance mensuel du volume d'articles.

Un topic avec des articles sémantiquement uniques ET en forte croissance est le signal faible idéal : activité anormale dans un domaine encore marginal, non encore absorbé par les thématiques dominantes.

3.3 Persistence score

Équation :

```
persistence = #{i : Delta[i] * Delta[i-1] > 0} / (n - 2)
```

```
Delta[i] = x[i] - x[i-1]
```

Mesure la proportion de paires de variations consécutives allant dans le **même sens**. La distinction avec Hurst est fondamentale :

Hurst	Mémoire LONGUE : persistance sur toute la série
Persistence	Cohérence LOCALE : les hausses sont-elles immédiatement suivies d'autres hausses ?

Exemple : [10, 12, 15, 13, 16, 20] -> deltas = [+2, +3, -2, +3, +4] -> paires cohérentes : (✓, ✗, ✗, ✓) -> persistence = 2/4 = 0,50

Calculé sur vol_active (mois avec au moins 1 article). Retourne 0,5 (neutre) si moins de 3 points.

3.4 Burst score (Kleinberg, 2002)

Modèle : automate de Poisson à K+1 états (défaut K=2)

```
lambda_k = mu * 2^k
```

```
emit(x, lambda) = lambda - x * log(lambda)
```

```
trans(q_prev, q) = max(0, q - q_prev) * log(n)
```

Algorithme de Viterbi -> séquence d'états optimale

L'automate est biaisé vers la **stabilité** : monter d'un état coûte log(n) par niveau, descendre est gratuit. Cela évite les fausses détections sur les petites fluctuations. Plus la série est longue, plus un changement d'état doit être justifié.

`État 0`	Activité normale
`État 1`	Burst niveau 1 : volume 2× au-dessus de la moyenne
`État 2`	Burst intense : volume 4× au-dessus de la moyenne

FAMILLE 3

4. Sémantique : Dynamic Semantic Trajectory (DST)

Ces trois métriques constituent le module **DST**, contribution originale qui pallie une limite de `topics_over_time` de BERTopic : cette méthode mesure la fréquence des mots mais pas si un topic *change de sens* dans le temps.

Le DST s'appuie sur les embeddings SPECTER (768 dimensions). Pour chaque topic k et mois t, un centroïde est calculé :

```
centroid(k, t) = (1 / |A[k,t]|) * Sum_{a in A[k,t]} emb(a)
```

où A(k,t) est l'ensemble des articles du topic k publiés au mois t.

4.1 Semantic drift

Équation :

```
drift[t] = 1 - cos(centroid[t-1], centroid[t])
```

```
drift[t] = 1 - (c[t-1] . c[t]) / (||c[t-1]|| * ||c[t]||)
```

La distance cosinus entre centroïdes consécutifs mesure si le topic **change de sens** d'un mois à l'autre, indépendamment du volume. Un topic 'machine learning' évoluant vers 'LLM fine-tuning' montrera un drift faible mais cumulatif.

`drift ~ 0,0`	Topic sémantiquement stable, même sujet traité
`drift ~ 0,1`	Légère évolution (seuil de détection TRANSFORMING)
`drift ~ 0,3`	Transformation notable du contenu
`drift ~ 0,5`	Mutation profonde du sujet

Note de calibration : le seuil TRANSFORMING est fixé à 0,10.

4.2 Keyword drift

Équation (similarité de Jaccard sur tokens) :

```
kw_drift[t] = 1 - J(T[t-1], T[t])
```

```
kw_drift[t] = 1 - |T[t-1] ∩ T[t]| / |T[t-1] ∪ T[t]|
```

où T_t est l'ensemble des **tokens individuels** (pas les phrases entières) des mots-clés KeyBERT du topic au mois t.

Pourquoi tokeniser ? Comparer les expressions complètes donnerait une similarité nulle pour "federated learning framework" vs "federated learning private" (aucune expression identique). En tokenisant, on obtient {federated, learning} comme tokens communs -> J = 3/7 ≈ 0,43, reflétant que le domaine est le même mais l'angle a changé.

Les tokens de longueur ≤ 2 sont filtrés pour réduire le bruit.

Complémentarité avec semantic drift : le drift sémantique opère dans l'espace continu des embeddings (sémantique profonde), le keyword drift dans l'espace discret du vocabulaire de surface. Un topic peut dériver sémantiquement sans changer de vocabulaire, ou inversement.

4.3 Stability score

Équation :

```
stability = exp(-delta_mean)
```

```
delta_mean = (1 / T) * Sum_{t=1..T} drift[t]
```

Le choix de la décroissance **exponentielle** plutôt que linéaire (1 - delta_mean) est délibéré : la fonction exponentielle est plus discriminante sur les valeurs intermédiaires.

`drift moy. 0,1`	**stability ≈ 0,90**	Très stable
`drift moy. 0,3`	**stability ≈ 0,74**	Légère évolution
`drift moy. 0,5`	**stability ≈ 0,61**	Évolution notable
`drift moy. 1,0`	**stability ≈ 0,37**	Forte instabilité
`drift moy. 2,0`	**stability ≈ 0,14**	Transformation profonde

Usage dans semantic_score : la stability est inversée (1 - stability) car on veut un score élevé pour les topics qui se *transforment*, pas pour ceux qui restent stables. Retourne 1,0 (stable par défaut) si la liste des dérives est vide.

5. Scores dimensionnels et score composite

Les 13 métriques brutes sont agrégées en trois scores dimensionnels dans [0, 1], puis combinées en un score composite via le `SignalScorer`.

Trend score (alpha)

```
trend_score = [ sigmoid(1.5*z) + sigmoid(0.5*a) + (tau+1)/2 + H +
sigmoid(2*CAGR) ] / 5 sigmoid(x) = 1 / (1 + exp(-x))
```

Weak signal score (beta)

```
ws_score = [ burst/burst_max + sigmoid(3*e) + sigmoid(3*NWE) + persistence
] / 4
```

Semantic score (gamma)

```
semantic_score = [ min(drift, 1) + min(kw_drift, 1) + (1 - stability) ] / 3
```

Score composite (approche hybride)

```
composite = (alpha * trend + beta * weak_signal + gamma * semantic) / (alpha
+ beta + gamma)
```

La division par (alpha + beta + gamma) garantit que le score reste dans [0, 1] quelle que soit la valeur des poids.

Pondération par défaut (approche hybride)

Les poids suivants sont utilisés dans l'implémentation de référence :

alpha (trend)	`0,4`
beta (weak signal)	`0,4`
gamma (semantic)	`0,2`

6. Classifieur : 6 états (TopicClassifier)

Le classifieur applique des **règles de priorité strictes** dans un ordre fixe. L'ordre reflète une hiérarchie métier : les états les plus informatifs ou les moins couverts par les approches volumétriques classiques sont traités en premier.

1	NEW	`n_months_active <= 2`

Historique trop court : aucune métrique statistique n'est fiable sous 3 mois d'observations.

2	EMERGING	`volume_faible ET emergence >= 0,15`

Volume faible = (n_articles <= 30) OU (part_catégorie <= 5%). La double condition couvre les petites catégories où 30 articles peut représenter un topic dominant. Implémente le signal faible au sens d'Ansoff (1975).

3	TRANSFORMING	`drift >= 0,10 ET |tau| <= 0,25`

Mutation sémantique sans tendance de volume notable. État original du projet : non détectable par les approches purement volumétriques. C'est la contribution principale de l'approche hybride.

4	TRENDING	`tau >= 0,40 ET p-value <= 0,05 ET Hurst OK`

Hurst >= 0,55 requis si n_months_active >= 10. En dessous, Hurst peu fiable, Mann-Kendall seul suffit. Double validation direction + persistance.

5	DECLINING	`tau <= -0,30 ET p-value <= 0,10`

Seuil de p-value plus souple que TRENDING (0,10 vs 0,05) car le déclin est moins actionnable mais utile pour filtrer le bruit de fond.

6	STABLE	`Aucune règle précédente`

État résiduel attribué par défaut. Activité régulière sans tendance notable.

Seuils clés de classification : EMERGING : max_articles=30, max_pct=5,0%, min_emergence=0,15 | TRANSFORMING : min_drift=0,10, max_|tau|=0,25 | TRENDING : min_tau=0,40, max_pval=0,05, min_hurst=0,55 | DECLINING : max_tau=-0,30, max_pval=0,10

7. Tableau récapitulatif des métriques

Métrique	Famille	Équation (résumé)	Normalisation	Série
`z_score`	Tendance	`(x[t] - mean_w) / std_w`	Sigmoïde scale=1,5	Complète
`ols_slope`	Tendance	`y = a t + b (régression OLS)`	Sigmoïde scale=0,5	Complète
`mann_kendall_tau`	Tendance	`tau = S / C(n,2)`	(tau + 1)/2	Active
`hurst_exponent`	Tendance	`pente log(R/S) ~ log(n)`	Clamp [0,1]	Active
`cagr`	Tendance	`(V_f / V_i)^(12/n) - 1`	Sigmoïde scale=2,0	Complète
`emergence_score`	Signal faible	`g[t] / log(1 + x[t])`	Sigmoïde scale=3,0	Complète
`novelty_wgt_emerg.`	Signal faible	`novelty[t] * g[t]`	Sigmoïde scale=3,0	Complète
`persistence_score`	Signal faible	`#{dir cohérents} / (n - 2)`	Clamp [0,1]	Active
`burst_score`	Signal faible	`Viterbi Poisson K états`	état / K_max	Complète
`semantic_drift`	Sémantique	`1 - cos(c[t-1], c[t])`	Clamp [0,1]	Centroids
`keyword_drift`	Sémantique	`1 - J(T[t-1], T[t])`	Clamp [0,1]	Keywords
`stability_score`	Sémantique	`exp(-delta_mean)`	1 - stability	Dérives

La force du système réside dans la **complémentarité des métriques** : Mann-Kendall détecte la direction, Hurst valide la persistance. Semantic drift opère dans l'espace continu des embeddings, keyword drift dans l'espace discret du vocabulaire. L'état TRANSFORMING est la pièce maîtresse : il rend visible ce que toutes les méthodes purement volumétriques manquent : un topic qui change de sens sans changer de taille.